Departamento Académico de Ingeniería C8286-Computación Paralela y Distribuida



Evaluación: Módulos 2 y 3 AWS Data Engineering

- Identificar las principales características y funciones de Amazon S3 que permiten el acceso y análisis de datos.
- Describir cómo se utilizan los servicios de Amazon S3 para almacenar y recuperar grandes volúmenes de datos.
- Configurar un bucket de Amazon S3 para almacenar datos de manera eficiente. Comparar las ventajas de usar Amazon S3 frente a otras soluciones de almacenamiento de datos en términos de coste y rendimiento.
- Evaluar las implicaciones de seguridad y privacidad al utilizar Amazon S3 en proyectos de análisis de datos
- Enumerar los cinco Vs de los datos: volumen, velocidad, variedad, veracidad y valor. Explicar cómo cada uno de los cinco Vs afecta la captura, el procesamiento y la visualización de datos.
- Utilizar un ejemplo práctico para demostrar cómo planificar y configurar una pipeline de datos considerando los cinco Vs
- Analizar los diferentes tipos de variabilidad de los datos (velocidad, volumen, etc.) influyen en las decisiones tecnológicas para proyectos de big data. datos haya impactado negativamente en los resultados del análisis de datos. Desarrollar un plan estratégico para implementar una pipeline de datos efectiva que maneje adecuadamente los cinco Vs y maximice el valor de los datos para una organización específica.

Instrucciones de entrega:

- Crea un documento en markdown que incluya una breve explicación de las partes que creas más importantes de tus respuestas junto con las capturas de pantalla o texto correspondiente del laboratorio: Lab: Accessing and Analyzing Data by Using Amazon S3
- Para el módulo 3 presenta la verificación del Knowledge Check
- Subir el documento final a tu repositorio personal hasta el día 5 de mayo (23:59).

Identificar las principales características y funciones de Amazon S3 que permiten el acceso y análisis de datos:

- Amazon S3 es un servicio de almacenamiento de objetos escalable y duradero, que permite almacenar y recuperar cualquier cantidad de datos, desde cualquier lugar de la web
- Algunas características clave de S3 que facilitan el acceso y análisis de datos son:
 - Escalabilidad ilimitada para almacenar grandes volúmenes de datos.
 - Múltiples clases de almacenamiento para optimizar el costo y el acceso.
 - Integración con otros servicios AWS como Athena, Redshift y EMR para análisis de datos.
 - Controles de acceso y seguridad flexibles para gestionar permisos.

Describir cómo se utilizan los servicios de Amazon S3 para almacenar y recuperar grandes volúmenes de datos:

- Los datos se pueden cargar en S3 a través de diversos mecanismos como la consola web, la CLI o SDK.
- Los objetos almacenados en S3 se organizan en "buckets" (cubos) que actúan como contenedores lógicos.
- S3 escala automáticamente para almacenar y procesar grandes cantidades de datos sin necesidad de aprovisionar.
- Los datos se pueden recuperar a través de consultas y descargas, o integrándolos con otros servicios analíticos de AWS.

Configurar un bucket de Amazon S3 para almacenar datos de manera eficiente:

- Definir una estructura de carpetas y nomenclatura para organizar los datos.
- Elegir la clase de almacenamiento adecuada según el patrón de acceso esperado.
- Habilitar características como versionamiento, ciclo de vida y cifrado para proteger los datos.
- Configurar políticas de acceso y permisos para controlar quién puede acceder a los datos.

Comparar las ventajas de usar Amazon S3 frente a otras soluciones de almacenamiento de datos en términos de costo y rendimiento:

- S3 ofrece un almacenamiento escalable y de bajo costo, especialmente para grandes volúmenes de datos.
- Proporciona un alto rendimiento y disponibilidad, adecuado para cargas de trabajo de análisis.
- Permite pagar solo por lo que se usa, sin necesidad de aprovisionar capacidad.
- Otras soluciones pueden tener costos más altos o requerir más mantenimiento y gestión por parte del usuario.

Evaluar las implicaciones de seguridad y privacidad al utilizar Amazon S3 en proyectos de análisis de datos:

- S3 proporciona controles de acceso flexibles y cifrado de datos en reposo y en tránsito.
- Es necesario configurar adecuadamente los permisos y políticas de acceso para evitar accesos no autorizados.
- Hay que considerar la ubicación geográfica de los buckets y cumplir con las regulaciones de privacidad de datos.
- Implementar prácticas de seguridad como registro de auditoría, monitoreo y

protección contra pérdida de datos.

Enumerar los cinco Vs de los datos: volumen, velocidad, variedad, veracidad y valor.

Explicar cómo cada uno de los cinco Vs afecta la captura, el procesamiento y la visualización de datos:

- **Volumen**: Impacta el diseño de la infraestructura de almacenamiento y procesamiento para manejar grandes cantidades de datos.
- **Velocidad**: Afecta la elección de tecnologías y arquitecturas para ingerir, procesar y analizar datos en tiempo real o por lotes.
- **Variedad**: Exige la capacidad de manejar diferentes formatos y estructuras de datos, y realizar transformaciones para integrarlos.
- **Veracidad:** Requiere procesos de limpieza, validación y gobernanza de datos para garantizar su integridad y fiabilidad.
- Valor: Determina qué datos son relevantes y valiosos para los objetivos de negocio, guiando las decisiones de captura y análisis.

Utilizar un ejemplo práctico para demostrar cómo planificar y configurar una pipeline de datos considerando los cinco Vs:

Por ejemplo:

Una empresa de comercio electrónico que quiere analizar el comportamiento de los clientes en su sitio web.

Volumen: Capturar y procesar registros de clics y eventos de navegación a gran escala.

Velocidad: Ingerir y procesar los datos de clics en tiempo real para realizar recomendaciones personalizadas.

Variedad: Integrar datos estructurados (transacciones) y no estructurados (text, imágenes) de diferentes fuentes.

Veracidad: Implementar procesos de limpieza y validación de datos para garantizar su integridad.

Valor: Identificar los datos más relevantes para analizar el comportamiento del cliente y mejorar la experiencia.

Analizar cómo los diferentes tipos de variabilidad de los datos (velocidad, volumen, etc.) influyen en las decisiones tecnológicas para proyectos de big data:

- El alto volumen de datos requerirá soluciones de almacenamiento escalables como Amazon S3.
- La necesidad de procesar datos en tiempo real implicará el uso de tecnologías de streaming como Amazon Kinesis.
- La variedad de datos estructurados y no estructurados sugerirá la adopción de plataformas flexibles como Amazon EMR.
- La veracidad de los datos impulsará la implementación de procesos de limpieza, validación y gobernanza.

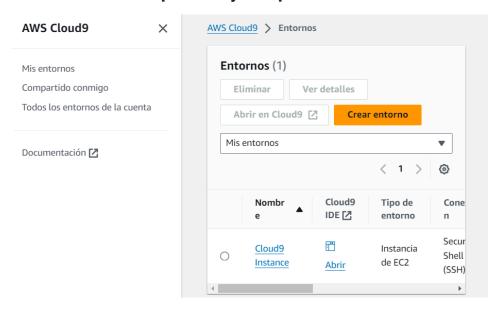
Desarrollar un plan estratégico para implementar una pipeline de datos efectiva que maneje adecuadamente los cinco Vs y maximice el valor de los datos para una organización específica:

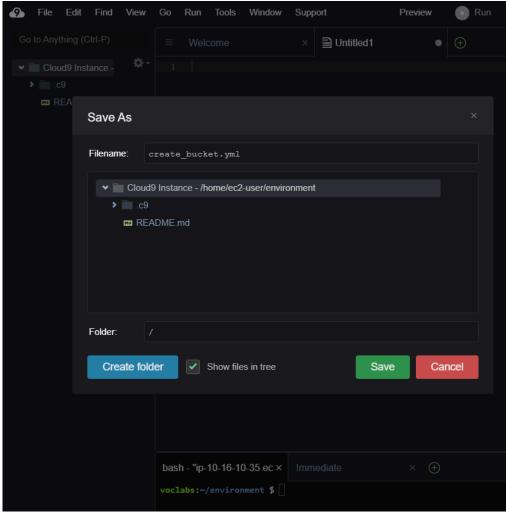
- Evaluar las necesidades de la organización en cuanto a los cinco Vs de los datos.
- Diseñar una arquitectura de pipeline de datos que incluya servicios como S3, Kinesis, Glue, Athena, etc.
- Implementar procesos de gobernanza de datos, limpieza, transformación e integración.
- Establecer mecanismos de visualización y análisis para extraer insights valiosos.

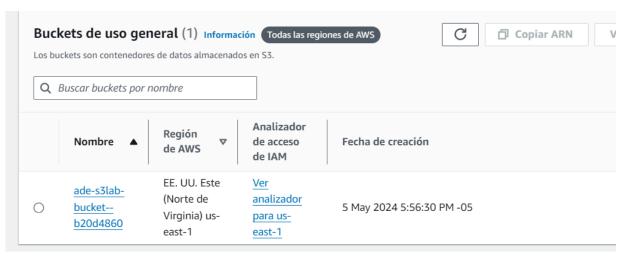
 Monitorizar y optimizar continuamente la pipeline para adaptarse a los cambios en los requisitos de datos.

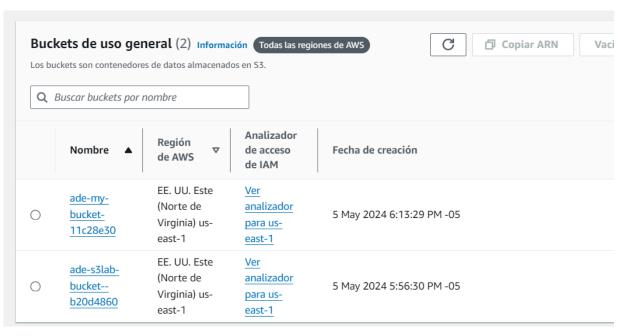
Lab:Accessing and Analyzing Data by Using Amazon S3

Tarea 1: Crear una plantilla y una pila de CloudFormation



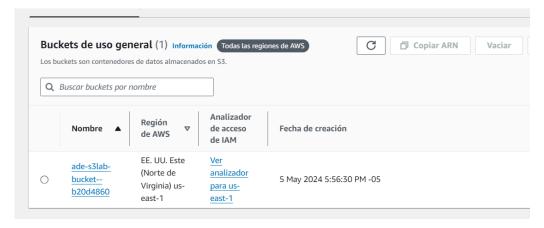






elimina

```
voclabs:~/environment $ aws cloudformation delete-stack --stack-name ade-my-bucket
voclabs:~/environment $
```



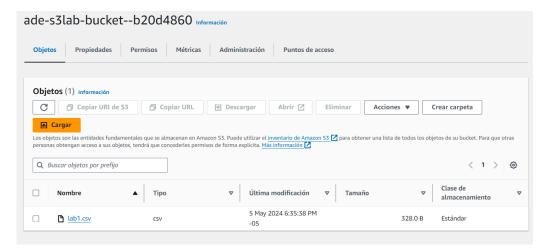
Tarea 2: cargar datos de muestra en un depósito de S3

```
voclabs:~/environment $ wget https://aws-tc-largeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.zip -P /home/ec2-user/environment .-2024-05-05 23:27:19- https://aws-tc-largeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.ziplargeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.ziplargeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.ziplargeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.ziplargeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.ziplargeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.ziplargeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.ziplargeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.ziplargeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.ziplargeobjects.s3.us-west-2.amazonaws.com/CUR-TF-200-ACDSCI-1-DEV/lab-01-s3/code.zip/s0-s2-zeb-22-zeb-20-s2-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22-zeb-22
```

```
voclabs:~/environment $ unzip code.zip
Archive: code.zip
inflating: lab1.csv
replace code.zip? [y]es, [n]o, [A]ll, [N]one, [r]ename: n
voclabs:~/environment $ 11
total 16
-rw-rw-r-- 1 ec2-user ec2-user 751 Sep 3 2022 code.zip
-rw-r--r-- 1 ec2-user ec2-user 836 May 5 23:04 create_bucket.yml
-rwxr-xr-x 1 ec2-user ec2-user 328 Sep 2 2022 lab1.csv
-rw-r--r-- 1 ec2-user ec2-user 569 Apr 30 02:48 README.md
voclabs:~/environment $
```

```
voclabs:~/environment $ cat lab1.csv
CustomerID,First Name,Last Name,Join Date,Street Address,City,State,Phone
1,Alejandro,Rosalez,12/12/2013,123 Main St.,Any Town,MD,301-555-0158
2,Jane,Doe,10/5/2014,456 State St.,Anywhere,WA,360-555-0163
3,John,Stiles,9/20/2016,1980 8th St.,Nowhere,NY,914-555-0122
4,Li,Juan,6/29/2011,1323 22nd Ave.,Anytown,NY,914-555-0149
voclabs:~/environment $ []
```

voclabs:~/environment \$ aws s3 cp lab1.csv s3://ade-s3lab-bucket--b20d4860
upload: ./lab1.csv to s3://ade-s3lab-bucket--b20d4860/lab1.csv
voclabs:~/environment \$ [



Tarea 3: Consultar los datos

Coı	nfiguración de entrada
Ruta	
s3:/	/ade-s3lab-bucketb20d4860/lab1.csv
Tam	año
328	.0 B
Forn	nato
0	CSV
O .	ISON
O A	Apache Parquet
CSV	delimitador
0	Coma
0 7	Гаbulador
O F	Personalizado
Com	Habilite esta configuración si CSV contiene una fila de encabezado. Inpresión Ninguno
	GZIP
	BZIP2
	Para crear un punto de referencia para escribir consultas SQL, puede mostrar los primeros 5·registros de datos de entrada ejecutando la siguiente consulta SQL: SELECT * FROM s3object s LIMIT 5 */ ECT * FROM s3object s LIMIT S
SQL	Ln 2, Col 33 & Errores: 0 Advertencias: 0
	os de la consulta de las consultas no están disponibles después de elegir Close (Cerrar) o salir de la página. Elija Download results (Descargar resultados) para descargar una copia de los siga a consulta.
stado) Se han d o /tes devuel	evuelto correctamente 4 registros en 1337 ms tos: 253 B
Sin proce	ssar Formateado



							< 1 >
1	Alejandro	Rosalez	12/12/2013	123 Main St.	Any Town	MD	301-555-0158
2	Jane	Doe	10/5/2014	456 State St.	Anywhere	WA	360-555-0163
3	John	Stiles	9/20/2016	1980 8th St.	Nowhere	NY	914-555-0122
4	Li	Juan	6/29/2011	1323 22nd Ave.	Anytown	NY	914-555-0149

1 /* Para crear un punto de referencia para escribir consultas SQL, ejecutando la siguiente consulta SQL: SELECT * FROM s3object

2 SELECT "First Name" FROM s3object s LIMIT 3

SQL Ln 2, Col 44 ⊗ Errores: 0 ⚠ Advertencias: 0

Resultados de la consulta

Los resultados de las consultas no están disponibles después de elegir **Close** (Cerrar) o salir de la pági resultados de la consulta.

Estado

Se han devuelto correctamente 3 registros en 1973 ms

Bytes devueltos: 20 B

Sin procesar	Formateado
1 Alejandro 2 Jane 3 John	
4	

Sin procesar

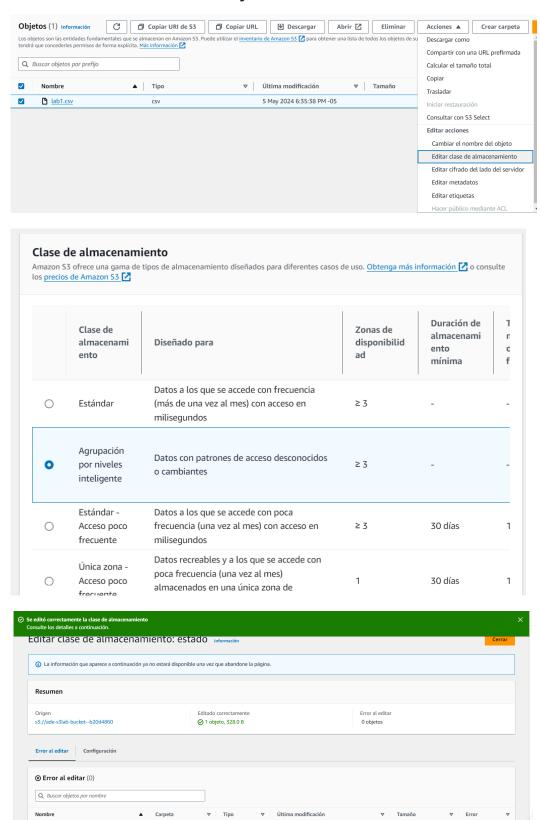
Formateado

Alejandro

Jane

John

Tarea 4: Modificar las propiedades de cifrado y el tipo de almacenamiento de un objeto



Tarea 5: comprimir y consultar el conjunto de datos

No hav ediciones con error

```
voclabs:~/environment $ zip lab lab1.csv
   adding: lab1.csv (deflated 29%)
 voclabs:~/environment $ 11
 total 20
 -rw-rw-r-- 1 ec2-user ec2-user 751 Sep 3 2022 code.zip
 -rw-r--r-- 1 ec2-user ec2-user 836 May 5 23:04 create_bucket.yml
 -rwxr-xr-x 1 ec2-user ec2-user 328 Sep 2 2022 lab1.csv
 -rw-rw-r-- 1 ec2-user ec2-user 398 May 5 23:59 lab.zip
 -rw-r--r-- 1 ec2-user ec2-user 569 Apr 30 02:48 README.md
 voclabs:~/environment $
 voclabs:~/environment $ gzip -v lab1.csv
                     29.3% -- replaced with lab1.csv.gz
voclabs:~/environment $ ls -la
total 24
drwxr-xr-x 3 ec2-user ec2-user 109 May 6 00:00 .
drwx----- 13 ec2-user ec2-user 4096 May 5 23:19 ...
drwxr-xr-x 5 ec2-user ec2-user 189 May 5 23:04 .c9
-rw-rw-r-- 1 ec2-user ec2-user 751 Sep 3 2022 code.zip
-rw-r--r-- 1 ec2-user ec2-user 836 May 5 23:04 create_bucket.yml
-rwxr-xr-x 1 ec2-user ec2-user 259 Sep 2 2022 lab1.csv.gz
-rw-rw-r-- 1 ec2-user ec2-user 398 May 5 23:59 lab.zip
-rw-r--r-- 1 ec2-user ec2-user 569 Apr 30 02:48 README.md
voclabs:~/environment $
voclabs:~/environment $ aws s3 cp lab1.csv.gz s3://ade-s3lab-bucket--b20d4860 --cache-control max-age=60
upload: ./lab1.csv.gz to s3://ade-s3lab-bucket--b20d4860/lab1.csv.gz
voclabs:~/environment $
ade-s3lab-bucket--b20d4860 Información
 Objetos Propiedades Permisos Métricas Administración Puntos de acceso
 Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el inventario de Amazon S3 🕻 para obtener una lista de todos los objetos de su bucket. Para que ot tendrá que concederles permisos de forma explícita. Más información 🕻
 Q Buscar objetos por prefijo
                                                                                     ▼ Clase de almacenamiento ▼
                      ▲ | Tipo
                                                                   ▼ Tamaño

▼ Última modificación

                                                 5 May 2024 6:57:33 PM -05
                                                                                     328.0 B Agrupación por niveles inteligente
 ☐ lab1.csv
                                                 5 May 2024 7:04:24 PM -05
                                                                                     259.0 B
                                                                                            Estándar
    lab1.csv.gz
Objetos (2) Información C O Copiar URI de S3 O Copiar URL O Descargar Abrir 🔀 Eliminar Acciones 🛦 Crear carpeta
Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el inventario de Amazon S3. Z para obtener una lista de todos los objetos de su tendrá que concederles permisos de forma explícita. Más información Z
                                                                                         Compartir con una URL prefirmada
Q Buscar objetos por prefijo
                                                                                         Calcular el tamaño total
                                                                                         Copiar
                         ▲ Tipo
Nombre

▼ Última modificación

                                                                         ▼ Tamaño
                                                                                         Trasladar
                                                     5 May 2024 6:57:33 PM -05
    lab1.csv
                                                     5 May 2024 7:04:24 PM -05
✓ lab1.csv.gz
                             gz
                                                                                         Consultar con S3 Select
                                                                                         Editar acciones
                                                                                          Cambiar el nombre del obieto
```

Editar clase de almacenamiento Editar cifrado del lado del servidor

Conf	figuración de entrada
Ruta	
s3://a	de-s3lab-bucketb20d4860/lab1.csv.gz
Tama	ño
259.0	В
Forma	ato
O CS	SV
O JS	ON
○ Ap	pache Parquet
CSV d	lelimitador
Co	oma
○ Ta	bulador
○ Pe	ersonalizado
✓ Ex	ccluir la primera línea de CSV datos
На	ibilite esta configuración si CSV contiene una fila de encabezado.
Comp	oresión
○ Ni	nguno
O G2	ZIP
○ BZ	ZIP2

```
1 /* Para crear un punto de referencia para escribir consultas SQL, puede SELECT * FROM s3object s LIMIT 5 */

2 SELECT * FROM s3object s limit 3

SQL Ln 2, Col 33 ⊗ Errores: 0 ⚠ Advertencias: 0
```

Resultados de la consulta

Los resultados de las consultas no están disponibles después de elegir Close (Cerrar) o salir de la página. Elija I

Estado

Se han devuelto correctamente 3 registros en 852 ms

Bytes devueltos: 193 B

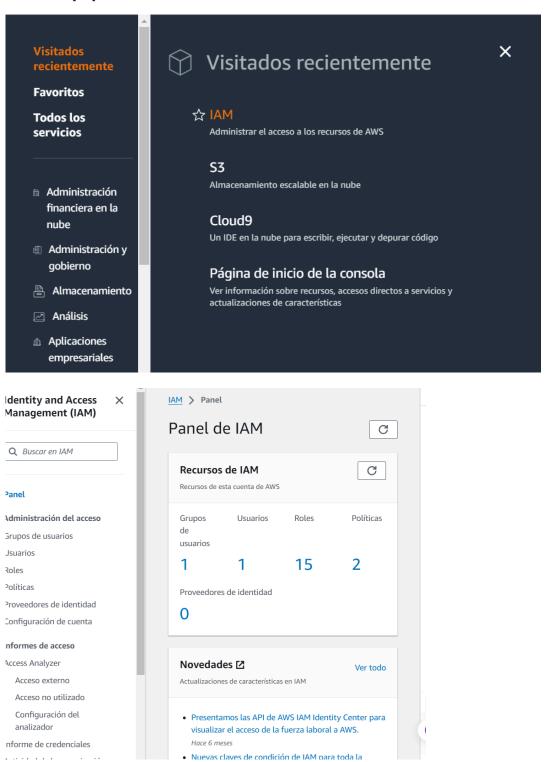
Sin procesar

Formateado

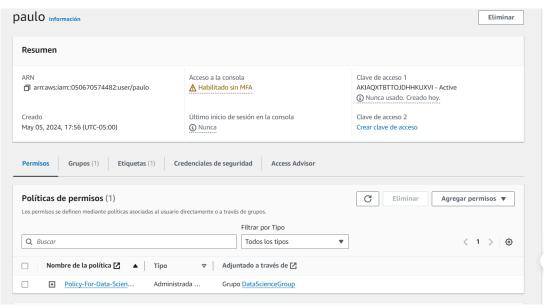
```
1 1,Alejandro,Rosalez,12/12/2013,123 Main St.,Any Town,MD,301-555-0158
2 2,Jane,Doe,10/5/2014,456 State St.,Anywhere,WA,360-555-0163
3 3,John,Stiles,9/20/2016,1980 8th St.,Nowhere,NY,914-555-0122
```

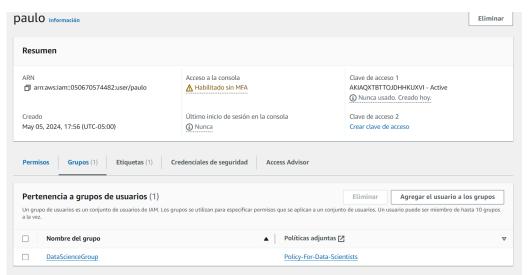


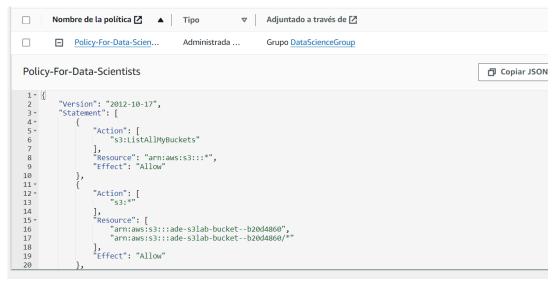
Tarea 6: Administrar y probar el acceso restringido para un miembro del equipo

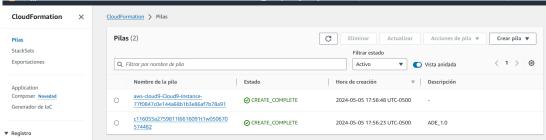


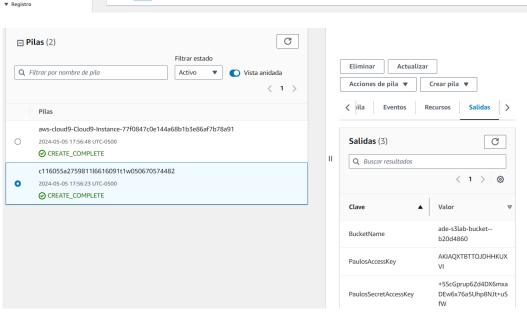












```
voclabs:~/environment $ AK=AKIAQXTBTTOJDHHKUXVI
voclabs:~/environment $ SAK=+5ScGprup6Zd4DX6mxaDEw6x76a5Uhp8NJt+uSfW
voclabs:~/environment $
```

```
voclabs:~/environment $ AWS_ACCESS_KEY_ID=$AK AWS_SECRET_ACCESS_KEY=$SAK aws e
c2 describe-instances --region us-east-1

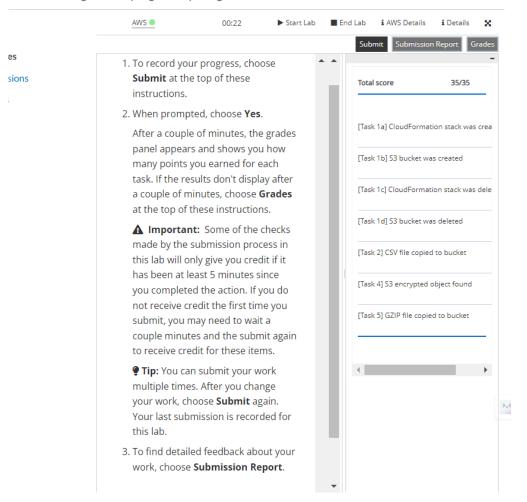
An error occurred (UnauthorizedOperation) when calling the DescribeInstances o
peration: You are not authorized to perform this operation. User: arn:aws:iam:
:050670574482:user/paulo is not authorized to perform: ec2:DescribeInstances b
ecause no identity-based policy allows the ec2:DescribeInstances action
voclabs:~/environment $ [
```

```
voclabs:~/environment $ AWS_ACCESS_KEY_ID=$AK AWS_SECRET_ACCESS_KEY=$SAK aws s
3api get-object --bucket ade-s3lab-bucket--b20d4860 --key lab1.csv --region us
-east-1 pulled_lab.csv
{
    "AcceptRanges": "bytes",
    "LastModified": "2024-05-05T23:57:33+00:00",
    "ContentLength": 328,
    "ETag": "\"1697af843916b88fbe887be65eb38a48\"",
    "ContentType": "text/csv",
    "ServerSideEncryption": "AES256",
    "Metadata": {},
    "StorageClass": "INTELLIGENT_TIERING"
}
voclabs:~/environment $ []
```

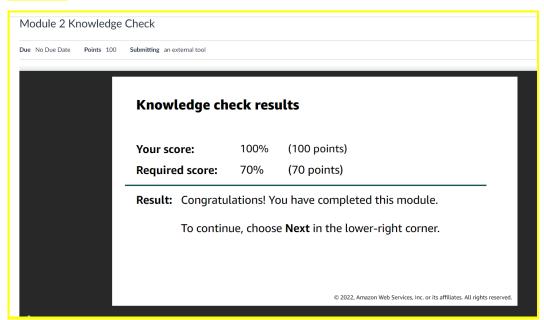
```
voclabs:~/environment $ cat pulled_lab.csv

CustomerID,First Name,Last Name,Join Date,Street Address,City,State,Phone
1,Alejandro,Rosalez,12/12/2013,123 Main St.,Any Town,MD,301-555-0158
2,Jane,Doe,10/5/2014,456 State St.,Anywhere,WA,360-555-0163
3,John,Stiles,9/20/2016,1980 8th St.,Nowhere,NY,914-555-0122
4,Li,Juan,6/29/2011,1323 22nd Ave.,Anytown,NY,914-555-0149
voclabs:~/environment $ [
```

> Lab: Accessing and Analyzing Data by Using Amazon S3



Module 2



Module 3

